



PILOTAGE DE LA PERFORMANCE E-COMMERCE : CAS OLIST

ZINEB OSFOURI




PILOTAGE DE LA PERFORMANCE

E-COMMERCE : CAS OLIST

CHOIX DE LA BASE DE DONNÉES (KAGGLE) :

Lien direct : [Brazilian E-Commerce Public Dataset by Olist](#)



Cette Bases de données contient des informations réelles sur **100 000** commandes passées **entre 2016 et 2018** sur plusieurs places de marché au Brésil. Les données couvrent le cycle de vie d'une commande : du statut de la commande au prix, en passant par la performance logistique, le paiement et les commentaires des clients

OBJECTIFS DE VISUALISATION :

Voici les 2 axes stratégiques que je vais présenter dans mon tableau de bord Qlik Sense :

1. **Analyse Commerciale :**


- Évolution du chiffre d'affaires (CA) par mois et par an.
- Top 5 des catégories de produits générant le plus de revenus.

2. **Analyse Client :**

- Répartition géographique des clients (Carte).
- Nombre moyen de commandes par client.

ÉTAPE 1 : MODÉLISATION DE L'ENTREPÔT DE DONNÉES SOUS MYSQL :



La phase de modélisation constitue le pilier central de l'architecture décisionnelle du projet, où l'objectif est de structurer l'entrepôt de données selon un schéma en étoile (Star Schema) optimisé pour l'analyse décisionnelle (OLAP). À l'aide de l'outil MySQL Workbench, nous avons conçu une Table de Faits centrale (Fact_Sales), regroupant les indicateurs quantitatifs (prix, frais de port) et les clés de liaison, entourée de Tables de Dimensions (Dim_Products, Dim_Customers, Dim_Calendar) qui fournissent les axes d'analyse descriptifs.




Note : En créant ces tables maintenant, tu définis le "contrat" de données. Talend devra respecter exactement ces noms de colonnes et ces types de données lors du chargement. C'est ce qu'on appelle la phase de Data Warehouse Design.


ÉTAPE 2 : LE PROCESSUS ETL AVEC TALEND

Le processus ETL a été réalisé sous Talend Open Studio afin de garantir l'intégrité et la propreté des données injectées dans le Data Warehouse. Cette étape a permis de mapper les champs techniques des fichiers CSV vers les dimensions du schéma en étoile, tout en gérant les types de données et les éventuelles valeurs manquantes.







File Delimited : Crée une connexion pour chaque fichier CSV. Cela permet à Talend de comprendre la structure (colonnes, types) de mes fichiers bruts.



Db Connections : Crée une connexion vers ma base MySQL **olist_warehouse** en utilisant les identifiants de ma nouvelle connexion "PROJET_BI_OLIST".


j'ai trois tables cibles (dim_customers, dim_products, et fact_sales), c'est idéal de créer trois Jobs différents (ou trois flux distincts) pour garder mon projet propre.

Flux pour dim customers





J'ai extrait les données sources du fichier des clients et j'ai appliqué un filtre d'unicité via le composant tUniqRow pour éliminer les doublons d'identifiants, garantissant ainsi que chaque client est unique dans ma base de données pour une analyse géographique précise.

Flux pour dim_products



J'ai nettoyé le catalogue des produits en supprimant les doublons et j'ai implémenté une règle de gestion des valeurs nulles avec le tMap (utilisant une condition Java) pour remplacer les catégories manquantes par la mention "Non défini", ce qui permet d'éviter les erreurs lors de l'analyse du Top 5 des catégories.


Flux pour fact_sales



J'ai réalisé une jointure de type "Inner Join" entre les fichiers des commandes et des articles et j'ai transformé les formats de données critiques, notamment en convertissant les prix en nombres (Float) et les chaînes de caractères en dates (TalendDate.parseDate), afin de permettre le calcul automatique du chiffre d'affaires et de son évolution dans le temps.

Schema en étoile

Pour permettre une analyse décisionnelle fluide et performante sous Qlik Sense, j'ai structuré les données transformées selon un schéma en étoile. Cette architecture est idéale en Business Intelligence car elle sépare les mesures quantifiables des données descriptives.



1. La Table de Faits : fact_sales

C'est le cœur du schéma. Elle contient les événements métiers (les ventes) et les clés permettant de lier les dimensions.

- **Métriques (Mesures)** : Elle stocke les données numériques calculables, notamment le prix (`price`) et les frais de port (`freight_value`).
- **Attribut temporel** : Le champ `order_purchase_timestamp` sert de base à toutes les analyses chronologiques, comme l'évolution du chiffre d'affaires par mois.
- **Clés étrangères** : Elle inclut les identifiants `product_id` et `customer_id` pour assurer l'intégrité référentielle avec les dimensions.

2. Les Tables de Dimensions


Elles entourent la table de faits et fournissent le contexte nécessaire à l'analyse.

- **dim_customers (Dimension Client)** :
 - Permet d'analyser les performances par zone géographique grâce aux attributs `customer_city` et `customer_state`.
 - C'est cette table qui alimente la visualisation cartographique du projet.
- **dim_products (Dimension Produit)** :
 - Contient l'attribut `product_category_name`.
 - Cette dimension est indispensable pour filtrer les ventes et identifier le Top 5 des catégories les plus rentables.

ÉTAPE 3 : ANALYSE DÉCISIONNELLE ET VISUALISATION (QLIK SENSE)

Initialement, le projet prévoyait une connexion dynamique via Qlik Data Gateway – Direct Access pour lier l'entrepôt de données local MySQL au Cloud de Qlik Sense. Cependant, face à des contraintes techniques liées à l'environnement système (dépendances des runtimes .NET) et pour garantir la continuité du projet dans les délais impartis, j'ai opté pour une stratégie d'intégration plus agile.

Le processus a donc consisté à effectuer un export manuel des données structurées depuis MySQL Workbench vers des fichiers plats au format CSV. Ces fichiers, contenant les tables finales (fact_sales, dim_customers et dim_products), ont ensuite été chargés directement dans l'interface Cloud.




The screenshot shows the Qlik Sense interface with the 'dim_customers' table selected. The table data is as follows:

customer_id	customer_city	customer_state
"0a0a4fa067e329684308c3b34046d8"	descalvado	SP
"0a0a7a0dea2d35a9a6be32e0945575d8"	sao paulo	SP
"0a0a7db3f0b06e9fd288ebab0f8a694"	fortaleza	CE
"0a0aa6d8a3c7535375d6fd935ae19480"	mogi das cruzeiras	SP
"0a0afd6b325c47238bc79033025b5a9e"	burri	SP

Associations recommandées:

- customer_id
- dim_customers:customer_id
- fact_sales:fact_sales.customer_id

Comme le montrent les captures d'écran ci-dessous, cette méthode n'a en rien altéré la qualité de l'analyse. J'ai pu reconstruire fidèlement le Schéma en Étoile au sein du moteur associatif de Qlik en établissant les relations sur les clés primaires customer_id et product_id. Cette approche a permis de sécuriser l'intégrité des jointures tout en offrant une performance de calcul optimale pour les visualisations finales.



The screenshot shows the Qlik Sense interface with the 'fact_sales' table selected. The table data is as follows:




order_id	fact_sales.product_id	fact_sales.c	dim_products.product_id	product_category_name
"00010242fe8c5a6d1ba2dd792cb16214"	"4244733e06e7ecb4970a6e2683c13e61"	"3ce436f183"	"00066f42aeeb9f3007548bb9d3f33c38"	perfumaria
"00018f772f0320c557190d7a144bdd3"	e5f2d52b802189ee658865ca93d83a8f	f6dd3ec061c	"00088930e925c41fd95ebfe695fd2655"	automotivo
"000229ec398224ef6ca0657da4fc703e"	c777355d18b72b67abbeef9df44fd0fd	"6489ae5e4"	"0009406fd7479715e4bef61dd91f2462"	cama_mesa_banho
"00024acbcdf0a6daa1e931b038114c75"	"7634da152a4610f1595efa32f14722fc"	d4eb9395c8	"000b8f95fcb9e0096488278317764d19"	utilidades_domesticas
			"000d9be29b5207b54e86aa1b1ac54872"	relorios_presentes

Associations recommandées:

- product_id
- dim_products:product_id

J'ai conçu quatre axes d'analyse prioritaires pour répondre à mes objectifs :

- **Analyse Commerciale (Temporelle)** : Un graphique en courbes illustrant l'évolution du chiffre d'affaires (CA) par mois, permettant d'identifier les pics d'activité saisonniers.
- **Performance Produits** : Un graphique en barres identifiant le Top 5 des catégories de produits générant le plus de revenus, grâce à une limitation de dimension fixe.
- **Analyse Géographique** : Une carte de points localisant la répartition des clients par ville, offrant une vision claire des marchés dominants.
- **Analyse de Fidélité** : Un indicateur de performance (KPI) calculant le nombre moyen de commandes par client



CONCLUSION :

Ce projet valide ma maîtrise de la chaîne de donnée "End-to-End". De l'intégration avec Talend à la visualisation sur Qlik Sense, j'ai transformé des données complexes en un outil de décision stratégique. Mon adaptabilité face aux défis techniques et ma compréhension des enjeux d'optimisation confirment mon profil de future Data Scientist.